

Consolidação das Informações da Reunião — IST / Projeto QuimioAnalytics

1. Origem dos dados e fluxo atual utilizado pelo IST

O laboratório utiliza o software Progenesis para geração e análise inicial dos dados.

Fluxo atual informado pela equipe:

1. Os dados são processados no Progenesis;
2. Bibliotecas configuradas dentro do software são utilizadas para enriquecimento/análise;
3. O próprio software gera automaticamente as planilhas de:
 - identificação;
 - abundância;
4. A equipe apenas exporta/baixa os arquivos antes da etapa de análise biológica.

Importante:

- As colunas não são preenchidas manualmente;
 - As planilhas são exportadas automaticamente pelo software;
 - Algumas métricas adicionais (tags) são configuradas pela própria equipe dentro das bibliotecas do sistema.
-

2. Explicação das principais colunas e métricas

Compound

Representa o sinal do composto analisado.

Neutral Mass

(Massa Neutra)

Considerada irrelevante para classificação biológica no contexto atual.

Definição:

Na química analítica, representa a massa da molécula em seu estado eletricamente neutro (sem carga), antes do processo de ionização utilizado na espectrometria de massa.

Retention Time (min)

(Tempo de retenção)

É o tempo que uma substância leva para percorrer o sistema cromatográfico desde a injeção até a detecção.

Interpretação prática:

Funciona como uma espécie de “identificador” da substância, pois diferentes compostos percorrem o sistema em velocidades diferentes.

Chromatographic Peak Width (min)

(Largura do pico cromatográfico)

Indica a eficiência da separação cromatográfica.

Interpretação:

- Picos estreitos → melhor separação e maior eficiência;
 - Picos largos → menor eficiência e maior dispersão.
-

Anova (p)

(p-value estatístico)

Mede a probabilidade de o resultado observado ocorrer por acaso.

Regra geral:

- $p \leq 0,05$:
Resultado estatisticamente significativo;
indica evidência de diferença/efeito real.
 - $p > 0,05$:
Resultado não significativo;
não há evidências suficientes para afirmar diferença real.
-

q Value

Refere-se ao quociente de reação.

Mede a relação entre concentrações de reagentes e produtos em determinado momento da reação química.

Max Fold Change

Indica quantas vezes um valor aumentou ou diminuiu em relação a outro.

No contexto do projeto:

Compara:

- Highest Mean
com
- Lowest Mean

Interpretação:

Valores maiores indicam maior diferença entre condições analisadas.

Isotope Distribution

(Distribuição isotópica)

Representa a proporção natural dos diferentes isótopos presentes em um elemento químico.

Maximum Abundance

(Abundância máxima)

Na espectrometria de massa:

Representa o pico de maior intensidade do espectro.

Características:

- É ajustado para 100% de abundância;
 - Os demais picos são calculados proporcionalmente a ele.
-

Minimum CV%

(Coeficiente de variação mínimo)

Utilizado para avaliar consistência experimental e variabilidade dos dados.

Interpretação:

- CV% alto:
maior dispersão e menor confiabilidade;
 - CV% baixo:
maior homogeneidade e melhor consistência amostral.
-

3. Tags adicionadas pela equipe

As tags são métricas/regras adicionais configuradas pela equipe através das bibliotecas do Progenesis.

Tags identificadas

Branco

Indica presença de espaço em branco na amostra.

Abund > 500

Abundância acima de 500.

Abund > 1000

Abundância acima de 1000.

Abund > 5000

Abundância acima de 5000.

Abund > 10000

Abundância acima de 10000.

Anova p-value <= 0.05

Indica significância estatística.

Max Fold Change >= 2

Considera-se compostos com Fold Change maior ou igual a 2.

Not Fragmented

Indica compostos que não sofreram fragmentação.

4. Informações importantes para o sistema de ordenação biológica

Nova regra de priorização definida na reunião

A ordenação biológica deverá considerar a seguinte sequência de prioridade:

1. fragmentation_score
 2. score
 3. isotope_similarity
 4. mass_error
 5. fórmula
-

5. Ajustes necessários no processo de validação

Foi definido que o campo:

- score

também deve ser incluído na validação da ordenação biológica.

Assim, os campos utilizados passam a incluir:

- feature_group
 - original_id
 - fragmentation_score
 - score
 - isotope_similarity
 - mass_error
 - fórmula
 - rank_group
 - is_tied
-

6. Conclusões principais da reunião

Confirmado

- O Progenesis gera automaticamente os dados;
 - As planilhas são exportadas diretamente do software;
 - A equipe não realiza preenchimento manual das colunas principais;
 - Existem regras adicionais configuradas por bibliotecas internas;
 - A ordenação biológica deve priorizar métricas específicas;
 - O score precisa ser incorporado à validação.
-

7. Impactos diretos no projeto QuímioAnalytics

Necessário atualizar

- Regras de ranking;
- Documentação técnica;
- Documentação biológica;
- Pipeline ETL;
- Processo de validação;
- Critérios de interpretação dos candidatos;
- Estrutura da planilha de revisão.

Estrutura Final Esperada do Projeto QuímioAnalytics

Objetivo Final

O resultado final do sistema será um dashboard interativo contendo os compostos classificados biologicamente, enriquecidos com informações químicas obtidas através de APIs externas e regras de ordenação validadas pelo IST.

O sistema atuará como uma camada de apoio à decisão científica, organizando automaticamente os candidatos mais relevantes para análise humana.

Estrutura Final da Saída

Colunas finais esperadas

Coluna	Descrição
Composto	Nome do composto identificado
Composto ID	Identificador único do composto
Modo de aquisição	Método/modo de aquisição do espectro
Score	Score geral de identificação/priorização
Fragmentação	Métrica de fragmentação utilizada na ordenação
Abund. relativa	Valor relativo de abundância do composto
Amostra mais abundante	Amostra onde o composto apresentou maior abundância
Descrição	Descrição química/biológica do composto
Classe geral	Classe química principal
Subclasse	Subcategoria química mais específica

Origem das Informações

Dados internos (planilhas exportadas do Progenesis)

As seguintes informações serão obtidas diretamente das planilhas exportadas pelo Progenesis:

- Compound
 - Compound ID
 - Acquisition Mode
 - Score
 - Fragmentation Score
 - Abundância
 - Informações das amostras
 - Métricas estatísticas
 - Métricas isotópicas
-

Dados enriquecidos por APIs externas

As seguintes informações serão buscadas automaticamente em bases químicas externas:

Informação	Fonte provável
Nome padronizado do composto	APIs químicas
Descrição química	PubChem / ChEBI
Classe geral	ClassyFire / PubChem
Subclasse	ClassyFire
Fórmula molecular complementar	APIs químicas
Metadados biológicos	Bases metabolômicas

Principais APIs/Bases previstas

Bases químicas principais

- PubChem
- ChEBI
- ClassyFire

Fluxo macro do sistema

1. Entrada

Recebimento das planilhas exportadas do Progenesis:

- identificação;
- abundância.

2. ETL e limpeza

Tratamento dos dados:

- remoção de inconsistências;
- normalização;
- padronização;
- integração das tabelas.

3. Ranking biológico

Aplicação da lógica validada pelo IST:

Sequência de priorização:

1. fragmentation_score
2. score
3. isotope_similarity
4. mass_error
5. formula

4. Enriquecimento químico

Consulta automática em APIs externas para obter:

- descrição;
- classe química;
- subclasse;

- metadados complementares.
-

5. Consolidação final

Geração da saída final:

- Excel;
 - CSV;
 - Dashboard;
 - relatórios analíticos.
-

Objetivo científico da saída

A saída final deve permitir que pesquisadores:

- identifiquem rapidamente compostos prioritários;
 - comparem abundâncias entre amostras;
 - interpretem relevância biológica;
 - visualizem classificação química;
 - reduzam análise manual repetitiva;
 - acelerem validação experimental.
-

Características esperadas do dashboard

Funcionalidades previstas

- filtros por classe química;
 - filtros por abundância;
 - busca por composto;
 - visualização de ranking;
 - destaque de candidatos prioritários;
 - análise comparativa entre amostras;
 - exportação para Excel/CSV;
 - indicadores estatísticos;
 - rastreabilidade da origem dos dados.
-

Resultado esperado do projeto

O QuimioAnalytics deixará de ser apenas um processo manual de revisão de planilhas e passará a funcionar como uma plataforma de apoio científico para priorização e interpretação metabolômica baseada em:

- dados laboratoriais;
- regras biológicas;
- classificação química automatizada;
- enriquecimento externo;
- validação humana especializada.