

Tabela de Identificação

Ps: Nathalia Parte das explicações foi elaborada com auxílio de inteligência artificial, devido a nossa falta de conhecimento na área. Se possível, poderia verificar as informações e indicar eventuais imprecisões ou pontos incorretos? Vou adicioná-la como comentadora no documento, para que possa fazer observações e sugestões diretamente no arquivo.

Compound	Compound ID	Adducts	Formula	Score	Fragmentation Score	Mass Error (ppm)	Isotope Similarity	Link	Description	Neutral mass (Da)
----------	-------------	---------	---------	-------	---------------------	------------------	--------------------	------	-------------	-------------------

Nome: Compound

Descrição: Identificador único do pico detectado durante a análise cromatográfica acoplada à espectrometria de massas (LC-MS ou GC-MS). Esse identificador é normalmente gerado automaticamente pelo software de processamento de dados e combina duas informações principais: o tempo de retenção (Retention Time – RT) e o valor da razão massa/carga (m/z) do íon detectado. O tempo de retenção corresponde ao momento em que o composto sai da coluna cromatográfica e é detectado pelo instrumento. Já o valor de m/z corresponde à razão entre a massa do íon e sua carga elétrica, sendo uma das principais características usadas para identificar moléculas em espectrometria de massas. Essas duas informações são separadas por um underscore (“_”), formando um identificador técnico do pico analítico. Em alguns casos, pode existir um sufixo adicional indicando o modo de ionização ou uma classificação interna do software. Esse campo não representa necessariamente o nome químico definitivo da molécula, mas sim um identificador técnico do sinal analítico detectado.

Tipo: Texto (string)

Exemplo: 9.03_455.2837n

Interpretação:

- **9.03** → tempo de retenção em minutos
- **455.2837** → valor de m/z detectado
- **n** → Quando aparece n após o valor da massa, é porque foram detectados adutos

Nome: Compound ID

Descrição: Identificador único do composto em uma base de dados química externa, como ChemSpider, HMDB ou outra base utilizada pelo software de identificação. Esse código permite relacionar o pico detectado experimentalmente com um composto químico conhecido, facilitando a consulta de informações adicionais como estrutura molecular, propriedades químicas, vias metabólicas e literatura científica. Esse identificador é importante na etapa de anotação ou identificação de metabólitos, pois conecta os dados experimentais com bancos de dados químicos amplamente utilizados na pesquisa científica.

Tipo: Texto (string)

Exemplo: CSID8961805

Nome: Adducts

Descrição: Indica o tipo de aduto formado durante o processo de ionização na espectrometria de massas. Durante a ionização, as moléculas raramente aparecem como espécies neutras; elas geralmente ganham ou perdem prótons ou se associam a outros íons, formando adutos. Esses adutos alteram o valor de m/z observado e precisam ser considerados durante a identificação do composto. Diferentes modos de ionização podem gerar diferentes tipos de adutos.

Exemplos comuns incluem:

- **M+H** → molécula protonada
- **M-H** → molécula desprotonada
- **M+Na** → molécula associada a sódio
- **M+K** → molécula associada a potássio

Tipo: Texto (string)

Exemplo: M-H

Nome: Formula

Descrição: Fórmula molecular do composto identificado. Essa fórmula indica a quantidade de cada elemento químico presente na molécula, como carbono, hidrogênio, oxigênio, nitrogênio, entre outros. A fórmula molecular é geralmente inferida a partir da massa exata do composto e comparada com bancos de dados químicos para sugerir possíveis estruturas moleculares compatíveis com os dados experimentais.

Tipo: Texto (string)

Exemplo:
C₂₀H₂₀O₈

Nome: Score

Descrição: Pontuação geral atribuída pelo software de identificação de compostos, indicando o grau de confiança da correspondência entre o sinal detectado no experimento e um composto presente na base de dados.

Esse valor geralmente é calculado considerando diversos fatores, como:

- precisão da massa detectada
- padrão isotópico
- fragmentação do espectro
- correspondência com banco de dados

Quanto maior o score, maior a probabilidade de que o composto identificado esteja correto.

Tipo: Numérico (float)

Exemplo: 35.2

Nome: Fragmentation Score

Descrição: Pontuação que avalia a qualidade da correspondência entre os fragmentos experimentais observados no espectro MS/MS e os fragmentos teóricos esperados para um determinado composto. Durante a espectrometria de massas em tandem (MS/MS), as moléculas podem se fragmentar em pedaços menores. Esses fragmentos formam um padrão característico que pode ser comparado com padrões teóricos ou bibliotecas espectrais. Quanto maior esse valor, melhor a correspondência entre os fragmentos detectados e os fragmentos esperados.

Tipo: Numérico (float)

Exemplo: 86.3

Nome: Mass Error (ppm)

Descrição: Erro entre a massa experimental medida pelo espectrômetro de massas e a massa teórica calculada para o composto, expresso em partes por milhão (ppm). Esse valor indica a precisão da medição da massa. Em espectrometria de alta resolução, valores de erro geralmente são muito pequenos.

- Valores próximos de 0 ppm indicam alta precisão.
- Valores muito altos podem indicar erro de identificação.

Tipo: Numérico (float)

Exemplo: -3.84

Nome: Isotope Similarity

Descrição: Medida que indica o grau de similaridade entre o padrão isotópico observado experimentalmente e o padrão isotópico teórico esperado para o composto. Os elementos químicos possuem diferentes isótopos naturais, o que gera padrões específicos de distribuição de massas no espectro. O software compara o padrão observado com o esperado para verificar se o composto identificado é compatível com o espectro experimental.

Valores mais altos indicam maior correspondência entre os padrões isotópicos.

Tipo: Numérico (float)

Exemplo: 80.73

Nome: Link

Descrição: Endereço eletrônico (URL) que direciona para uma página em uma base de dados química externa, contendo informações detalhadas sobre o composto identificado.

Essas informações podem incluir:

- estrutura molecular
- propriedades físico-químicas
- dados espectrais
- literatura científica relacionada
- vias metabólicas

Esse campo facilita o acesso rápido às informações adicionais do composto.

Tipo: Texto / URL

Exemplo: <http://nonlinear.com/redirect/outbound?p=chemspider¶m=8961805>

Nome: Description

Descrição: Esse campo está relacionado ao campo Link, ou seja, o metabólito identificado pela biblioteca utilizada é nomeado na coluna "Description" e um link com características desse composto é disponibilizado na coluna "Link". As informações disponibilizadas pelo link podem ser utilizadas no momento de caracterizar as moléculas quanto sua origem, aplicação e classe química. Às vezes, a informação do link não é completa e, por isso, buscamos bases externas como as que citei nos slides (pubchem, kegg, chebi, etc) para complementar

O nome pode vir de bases de dados químicas ou bibliotecas espectrais utilizadas pelo software de identificação.

Tipo: Texto (string)

Exemplo:
Saudinolide

Nome: Neutral mass (Da)

Descrição: Massa molecular do composto em sua forma neutra, ou seja, sem considerar a presença de carga elétrica ou adutos formados durante a ionização. Esse valor é geralmente calculado a partir da fórmula molecular e expresso em Daltons (Da), unidade padrão de massa atômica utilizada em química e espectrometria de massas.

Tipo: Numérico (float)

Exemplo: 387.10704987703

Nome: m/z

Descrição: Razão entre a **massa do íon detectado e sua carga elétrica (mass-to-charge ratio)**. Esse é um dos parâmetros fundamentais da espectrometria de massas, pois o espectrômetro mede diretamente essa razão para detectar e separar os íons presentes na amostra. O valor de m/z permite identificar compostos com base em suas massas moleculares e nos padrões de fragmentação.

Tipo: Numérico (float)

Exemplo: 455.2837

Nome: Retention Time (min)

Descrição: Tempo necessário para que um composto atravessasse a coluna cromatográfica e seja detectado pelo instrumento. Esse valor é medido em minutos. O tempo de retenção depende das propriedades físico-químicas da molécula, como polaridade, interação com a fase estacionária da coluna e condições experimentais da análise. Ele é utilizado junto com o valor de m/z para ajudar na identificação e diferenciação de compostos presentes na amostra.

Tipo: Numérico (float)

Exemplo: 9.03

Tabela ABUND

Nome: Composto (Compound)

Descrição: Identificador do composto detectado no experimento. Esse identificador geralmente é gerado automaticamente pelo software de processamento de dados analíticos. O nome normalmente segue um padrão que combina duas informações principais: o tempo de retenção do composto na coluna cromatográfica e o valor de massa detectada no espectrômetro de massas. Em alguns casos,

uma letra adicional como o 'n' indica que foram encontrados adutos e a massa do composto foi encontrada, posto isto, m/z significa que não foram encontrados adutos

. Esse campo funciona como um identificador do pico detectado, permitindo rastrear o mesmo composto em diferentes amostras analisadas.

Tipo: VARCHAR

Exemplo: 9.03_455.2837n

Nome: *Massa Neutra (Neutral Mass – Da)*

Descrição: Indica a massa molecular neutra estimada do composto, expressa em Daltons (Da). Em espectrometria de massas, os compostos normalmente são detectados como íons carregados, e não na forma neutra. Por isso, o software realiza cálculos para estimar qual seria a massa do composto sem carga elétrica. Essa informação é importante para comparar compostos com bancos de dados químicos, propor fórmulas moleculares e auxiliar na identificação estrutural das moléculas detectadas.

Tipo: FLOAT

Exemplo: 455.28369970654

Nome: *m/z*

Descrição: Representa a relação massa/carga (mass-to-charge ratio) do íon detectado no espectrômetro de massas. Esse é um dos parâmetros fundamentais da espectrometria de massas, pois corresponde ao valor medido diretamente pelo equipamento. A variável m representa a massa do íon detectado e z representa o número de cargas elétricas desse íon. Como a maioria dos íons possui carga +1 ou -1, o valor de m/z costuma ser muito próximo da massa do composto. Esse dado é essencial para a identificação de compostos e análise de suas assinaturas espectrais.

Tipo: FLOAT

Exemplo: 454.27642327454

Nome: *Tempo de Retenção (Retention Time – min)*

Descrição: Indica o tempo que o composto levou para atravessar a coluna cromatográfica e ser detectado pelo sistema analítico, expresso em minutos. Durante o processo de cromatografia, os compostos são separados de acordo com suas propriedades químicas e interações com a fase estacionária da coluna. Cada substância possui um tempo de retenção característico, que pode variar de acordo com fatores como polaridade, afinidade com a coluna, condições do método analítico e composição da fase móvel. Esse parâmetro é importante para auxiliar na identificação de compostos e diferenciar moléculas com massas semelhantes.

Tipo: FLOAT

Exemplo: 49.03026666666667

Nome: Largura do Pico Cromatográfico (Chromatographic Peak Width – min)

Descrição: Representa a largura do pico cromatográfico associado ao composto detectado, medida em minutos. Durante a cromatografia, cada composto aparece no cromatograma como um pico. A largura desse pico indica quanto tempo o sinal do composto permaneceu sendo detectado. Picos mais estreitos geralmente indicam melhor separação cromatográfica e maior eficiência da coluna, enquanto picos mais largos podem indicar sobreposição com outros compostos ou menor eficiência de separação. Essa informação pode ser utilizada para avaliar a qualidade da análise cromatográfica.

Tipo: FLOAT

Exemplo: 0.177733333333333

Nome: Identificação do Composto (Identifications)

Descrição: Indica quantas possíveis moléculas (compostos químicos) estão associadas a um determinado sinal analítico detectado. Esse número não corresponde a uma identificação definitiva, mas sim à quantidade de candidatos que podem explicar aquele sinal com base nos dados obtidos, como m/z, tempo de retenção e padrões espectrais. Para saber exatamente quais são essas moléculas e avaliar quais fazem mais sentido, é necessário consultar a tabela de “Identificação”, onde os compostos estão listados de forma detalhada. Por exemplo, um valor de 53 nessa coluna significa que existem 53 possíveis compostos relacionados àquele sinal analítico. Esse campo é importante porque mostra o nível de incerteza na identificação, algo comum em estudos de metabolômica e análises químicas. (no caso da tabela de abundância, a coluna "Identifications" apenas diz quantas possíveis moléculas foram encontradas para cada sinal analítico. Para entender quais são essas moléculas e quais fazem sentido, precisamos ir até a tabela de "Identificação", onde estas moléculas identificadas estarão listadas. Em resumo: A coluna que possui 53 identificações na tabela de Abundância, significa que para o sinal analítico avaliado, foram identificados 53 possibilidades de compostos)

Tipo: INTEGER

Exemplo: 147

Nome: Abundância nas Amostras (Colunas 1.1 até 6.2)

Descrição: Conjunto de colunas que representam os valores de abundância ou intensidade relativa do composto em diferentes amostras experimentais. Esses valores normalmente correspondem à área do pico cromatográfico ou à intensidade do sinal detectado no espectrômetro de massas. Quanto maior o valor registrado, maior é a quantidade relativa do composto presente naquela amostra. A nomenclatura segue o padrão Grupo.Replicata, no qual o primeiro número representa o grupo experimental e o segundo número representa a replicata daquela amostra. Esses dados são utilizados

para comparar a abundância de compostos entre diferentes grupos experimentais, identificar diferenças metabólicas entre amostras e realizar análises estatísticas em estudos experimentais.

Tipo: FLOAT

Exemplo: 102834.117411157

Tabela Final

Nome: id_composto (ID)

Descrição: Identificador único atribuído a cada amostra avaliada registrado no banco de dados. Esse campo permite distinguir cada registro individualmente e facilita a organização e busca das informações no sistema. O identificador pode seguir um padrão que indique informações como o solvente utilizado, o modo de ionização e um número sequencial da amostra, permitindo maior rastreabilidade dos dados experimentais.

Tipo: VARCHAR(12)

Exemplo: AcEt_POS_001

Nome: Metabolito/Composto

Descrição: Campo destinado ao armazenamento do nome científico ou nomenclatura química do composto identificado na análise. Esse nome segue padrões de nomenclatura química reconhecidos internacionalmente, permitindo a identificação correta da substância e sua comparação com registros de bases de dados químicas e publicações científicas.

Tipo: VARCHAR(50)

Exemplo: 3-(4-Methoxyphenyl)-2-methyl-2-propenal

(Nome: Solvente) - Não Necessário

Descrição: Indica a substância química utilizada como solvente no processo de extração dos metabólitos presentes em uma amostra biológica. Diferentes solventes podem influenciar quais compostos são extraídos com maior eficiência, sendo importante registrar essa informação para garantir a reprodutibilidade das análises e a correta interpretação dos resultados.

Tipo: VARCHAR

Exemplo: Acetato de Etila

(Nome: Modo de Ionização) -

Descrição: Define a polaridade elétrica aplicada na fonte de ionização do espectrômetro de massas durante a análise do composto. O modo pode ser positivo ou negativo, dependendo da forma como a molécula interage com o processo de ionização, o que influencia diretamente na detecção e identificação do composto.

Tipo: VARCHAR

Exemplo: Positivo

Nome: Categoria química

Descrição: Representa a classificação do composto com base em sua estrutura molecular ou no grupo funcional predominante. Essa classificação ajuda a organizar os compostos dentro do banco de dados e facilita análises comparativas entre moléculas pertencentes à mesma família química.

Tipo: VARCHAR

Exemplo: Aldeído aromático

Nome: Metabolismo

Descrição: Campo destinado ao registro de observações relacionadas à função biológica, origem metabólica ou natureza da molécula. Pode indicar, por exemplo, se o composto é produzido naturalmente pelo organismo ou se é uma substância externa introduzida no sistema biológico.

Tipo: VARCHAR

Exemplo: Xenobiótico

Nome: Via metabólica

Descrição: Indica a rota bioquímica ou processo metabólico no qual o composto participa ou é formado. O registro dessa informação permite relacionar o composto a processos celulares específicos e auxilia em estudos sobre metabolismo e transformações químicas no organismo.

Tipo: VARCHAR

Exemplo: Biotransformação hepática

Seção de Dúvida

1. Como os scores são calculados no sistema?

Quando rodamos as bibliotecas para identificar os compostos no Progenesis, o match dessa identificação do composto da biblioteca e do composto analisado no equipamento é um número, chamado de score. O score compara o perfil de fragmentação do analito no equipamento (experimental) com o perfil de fragmentação do analito na biblioteca (geralmente, teórico) e a comparação do perfil experimental + teórico é o score. Por isso que, quanto maior este valor, melhor - temos mais "pontos" para um composto com um score alto. Quando falamos de score de fragmentação, o raciocínio é o mesmo, mas vocês vão observar que nem todos os compostos têm um valor nesta coluna. Isso ocorre porque nem toda biblioteca tem o composto fragmentado experimentalmente e aí esse match não ocorre. Poucas são as bibliotecas que possuem informações de fragmentação experimental disponíveis e esta é a razão para ele ser mais importante que o score: quando há uma boa pontuação do score de fragmentação, é porque foi utilizada uma biblioteca que tem esse dado experimental e quando comparado com o nosso (tbn experimental) for uma pontuação alta, ele traz mais certeza quanto a identidade do composto

2. Quais parâmetros ou critérios definem se um score é considerado bom ou ruim?

Acho que respondi acima, qualquer dúvida me escreva novamente.

3. Como são calculados especificamente:

- *o Score de Fragmentação?*
- *match de fragmentação a partir da biblioteca*

- *o Score geral (Score total)?*
match de fragmentação a partir da biblioteca
- *a Similaridade isotópica?*
similaridade do perfil isotópico encontrado na análise comparado ao perfil teórico. Quanto maior esse valor, mais parecido eles são

4. Poderiam descrever com o máximo de detalhes possível como esses cálculos são feitos e quais dados são utilizados?

Acho que essa pergunta também está respondida na questão 1

5. Existe documentação oficial ou material de referência do aplicativo/sistema que vocês utilizam, o Progenesis?

Aqui tem o manual do software Progenesis:

https://nldstorage.blob.core.windows.net/webfiles/progenesis/qi/v1.0/user-guide/Progenesis_QI_User_Guide_1.0.pdf

Ressalto o que falei na próxima pergunta: é um software bem técnico e não vejo tanta aplicação para vocês. Qualquer coisa, me escrevam.

6. Seria possível disponibilizar uma explicação mais detalhada sobre o funcionamento do software, como por exemplo:

- *uma aula gravada explicando as principais funcionalidades demonstrando o uso do sistema?*

Se você digitar “Progenesis QI” no Google, vão aparecer alguns vídeos da Waters Corporation. Lá tem algumas explicações de como funcionam o software, caso vocês tenham interesse em compreender um pouco o trabalho que fazemos do lado de cá. Entretanto, acredito que a parte do software não precise ser levada em consideração, uma vez que os inputs do programa que vocês desenvolverão serão as tabelas exportadas do software.

Nesta página tem um resumo de como o Progenesis funciona:
<https://www.nonlinear.com/progenesis/qi/how-it-works/>

Na mesma página, na barra lateral esquerda tem o FAQ e outros links interessantes.

7. O que significam as colunas destacadas em vermelho nas tabelas?

São as colunas que podem ser desconsideradas, pois não agregam informação para a tomada de decisão

8. Entre todas as informações presentes nas planilhas, quais dados vocês consideram mais importantes para a análise dos compostos?

Os que não estão em vermelho, na ordem de prioridade de: score de fragmentação (quanto maior, melhor), score (quanto maior, melhor) e similaridade isotópica (maior que 80)

9. A descrição das colunas e das informações de cada tabela, presente no documento que elaboramos, está correta?

Fiz comentários direto no descritivo que vocês realizaram ;)

10. Quais são exatamente os dados da ontologia que vocês precisam que sejam coletados ou estruturados?

Seria interessante obtermos informações da ontologia biológica/taxonomia (em que organismos/espécies o composto pode encontrado), como também da ontologia/classificação química (ou bioquímica, funcional). Por exemplo, no Pubchem, a molécula quercetina apresenta dados de taxonomia e também de classificação química. Para nós seria interessante extrair essas informações. Na parte de classificação, a quercetina é classificada de diferentes formas (química, bioquímica, funcional) segundo as diferentes base de dados (Mesh, NCI, Chebi, etc)...seria bom extrair todos esses dados.

Quando disponível, seria também interessante extrair outros dados como:

- 1. nomes e identificadores (seção Pubchem: names and identifiers)*
- 2. aditivos alimentares (food additives)*
- 3. aplicações (uses and manufacturing)*
- 4. segurança (safety)*
- 5. toxicidade (toxicity)*

link do exemplo: <https://pubchem.ncbi.nlm.nih.gov/compound/Quercetin>

11. Em relação à taxonomia, qual nível de classificação é necessário incluir? Por exemplo:

- *espécie*
- *gênero*
- *família*
- *reino*
- *ou outros níveis taxonômicos?*
Geralmente o que vem descrito é gênero e espécie (às vezes com nome comum também), como no exemplo acima.
-

12. Até que ponto deve ir o levantamento de usos e aplicações conhecidas da molécula?

- *apenas aplicações principais*
- *aplicações experimentais*
- *usos industriais ou farmacológicos*
- *ou qualquer referência disponível na literatura?*
Ver ponto 10.

13. Existe a possibilidade de realizarmos uma visita para observar o processo de identificação e classificação dos compostos, para entender melhor o fluxo de trabalho e as etapas da análise?

Claro! São bem-vindos.

14. Quais tipos de visualização vocês consideram mais úteis durante a análise no sistema? (por exemplo: gráficos, mapas de calor, redes moleculares, espectros, etc.)

Depende do que está sendo analisado, mas geralmente usamos gráficos de pizza, sunburst, heatmap, barras e dispersão.

15. Quais gráficos ou representações visuais vocês utilizam com mais frequência para validar ou interpretar os resultados?

Ver 14.

16. Como foi realizada a identificação dos compostos listados na coluna “Identifications”?

Gostaríamos de entender qual foi o método utilizado para essa atribuição. Por exemplo, se a identificação foi feita por:

- *comparação com bibliotecas ou bancos de dados espectrais,*
- *utilização de padrões analíticos,*
- *algoritmos do software de anotação/identificação,*
- *ou apenas com base em massa exata (m/z) e tempo de retenção.*

Após executarmos a busca de candidatos para a identificação putativa (anotação) dos compostos detectados, utilizando bibliotecas personalizadas ou de banco de dados, analisamos o score (que se baseia no erro de massa/carga, similaridade espectral e isotópica), espectro de fragmentação e a plausibilidade biológica/química (faz sentido tal estrutura estar presente na amostra? É plausível e esperado?) para escolher o melhor candidato para cada composto.

17. O que representam exatamente os valores presentes nas colunas de da tabela abundância (por exemplo: 1.1, 1.2, 2.1, etc.)? Está certo como descrito lá em cima?

A abundância relativa em metabolômica baseada em LC-MS (Cromatografia Líquida acoplada à Espectrometria de Massas) é uma abordagem analítica que determina a proporção de um metabólito específico em comparação com outros na amostra, em vez de sua concentração absoluta.

18. Como foi calculado o valor de “Neutral mass (Da)” a partir do valor de m/z ? foi considerado algum tipo específico de ionização ou formação de adutos químicos, já

que diferentes processos de ionização podem alterar a relação entre massa neutra e m/z .

A massa neutra é atribuída a um composto se dois ou mais adutos daquele composto tiverem sido detectados. O software calcula a massa neutra por deconvolução, como explicado no link a seguir:

<https://www.nonlinear.com/progenesis/qi/v3.1/faq/how-does-deconvolution-work.aspx>

19. Foi aplicado algum critério de qualidade ou filtragem aos compostos detectados antes da geração da tabela final? Por exemplo intensidade mínima do sinal, qualidade do pico cromatográfico, reprodutibilidade entre replicatas, ou outros parâmetros de confiabilidade.

Geralmente filtramos dados com alta abundância no branco ou de baixa abundância (ex. <1000-10000, dependendo do experimento).